

Sistemi za obradu i analizu velikih podataka

Upravljanje i analiza velikih skupova podataka

Projekat 1 – 2025/26

Analiza velikih podataka

- Izabrati jedan od navedenih velikih skupova podataka (~ 1GB) i prijaviti izabrani dataset slanjem maila da bi se izbeglo dupliranje projekata. Ukoliko od prijave teme do odbrane projekata prođe više od 6 meseci, izbor teme je nevažeći.
 - [College Experience Study Dataset](#)
 - [Download OpenStreetMap for OpenStreetMap Data Extracts | Geofabrik Download Server](#)
 - [EmissionOutput - SUMO Documentation](#)
 - [HUPA-UCM Diabetes Dataset - Mendeley Data](#)
 - [The University of Queensland Vital Signs Dataset](#)
 - [IoT network intrusion dataset | IEEE DataPort](#)
 - [Edge-IIoTset: A New Comprehensive Realistic Cyber Security Dataset of IoT and IIoT Applications: Centralized and Federated Learning | IEEE DataPort](#)
 - [Battery and Heating Data in Real Driving Cycles | IEEE DataPort](#)
 - [AIS Signal and Channel Dataset from Tórshavn Harbor and Surrounding Islands \(Faroe Islands\) | IEEE DataPort](#)
 - [The Piraeus AIS Dataset for Large-scale Maritime Data Analytics](#)
- Download-ovati, preprocesirati, re-formatirati, eventualno generisati dopunu do ~1GB i postaviti podatke na HDFS.
- Razviti aplikaciju korišćenjem Apache Spark framework-a i Python (Scala, Java) API za batch obradu i analizu ovih podataka koja uključuje sledeće funkcionalnosti:
 - Filtriranje, sortiranje, prebrojavanje i prikaz atributa u podacima na osnovu parametara koji se zadaju kao argumenti aplikacije (npr. broj događaja povišene glukoze u zadatom periodu, ili ukupan broj vozila na rakersnici).
 - Nalaženje minimalne, maksimalne, srednje vrednosti, standardne devijaciju i ostale statističke parametre određene(-ih) atributa grupisane po zadatom atributu (npr. lokaciji/oblasti, vremenu,...) koji se zadaju kao argumenti aplikacije.
- Izvršiti testiranje, evaluaciju i analizu performansi samostalne Python/Java aplikacije, kao i Spark aplikacije na klasteru Spark Docker container-a, pri čemu se aplikacija startuje kao poseban kontejner povezan sa klasterom u zajedničku lokalnu mrežu.
- Pripremiti prezentaciju sa opisom projekta i značajnim detaljima implementacije. Ovu prezentaciju i izvorni kod projekta postaviti na GitHub.